国嵌

www.enjoylinux.cn

Linux内核开发

谢伟 著

Contents

Contents

内存管理子系统

内存是Linux内核所管理的最重要的资源之一，内存管理子系统是操作系统中最重要的部分之一。对于立志从事内核开发的工程师来说，熟悉Linux的内存管理系统非常重要。

地址类型

- 物理地址
- 线性地址（虚拟地址）
- 逻辑地址

他们之间的关系？

物理地址

物理地址是指出现在CPU外部地址总线上的寻址物理内存的地址信号，是地址变换的最终结果。

逻辑地址

程序代码经过编译后

在汇编程序中使用的地址。

线性地址

线性地址又名虚拟地址，在32位CPU架构下，可以表示4G的地址空间，用16进制表示就是0x00000000到0xffffffff。

地址转换

CPU要将一个逻辑地址转换为物理地址，需要两步：首先CPU利用段式内存管理单元，将逻辑地址转换成线程地址，再利用页式内存管理单元，把线性地址最终转换为物理地址。

段式、页式管理

- 什么是段式管理?
- 什么是页式管理?

段式管理(16位CPU)

16位CPU内部拥有20位的地址线，它的寻址范围就是2的20次方，也就是1M的内存空间。但是16位CPU用于存放地址的寄存器（IP，SP……）只有16位，因此只能访问65536个存储单元，64K。

段式管理(16位CPU)

为了能够访问1M的内存空间，CPU就采用了内存分段的管理模式，并在CPU内部加入了段寄存器。16位CPU把1M内存空间分为若干个逻辑段，每个逻辑段的要求如下：

1、逻辑段的起始地址(段地址)必须是16的倍数，即最后4个二进制位必须全为0。

2、逻辑段的最大容量为64K(why?)

段式管理(16位CPU)

物理地址的形成方式:

由于段地址必须是16的倍数，所以值的一般形式为XXXX0H，即前16位二进制位是变化的，后四位是固定的0，鉴于段地址的这种特性，可以只保存前16位二进制位来保存整个段基地址，所以每次使用时要用段寄存器左移补4个0（乘以16）来得到实际的段地址。

段式管理(16位CPU)

在确定了某个存储单元所属的段后，只是知道了该存储单元所属的范围（段地址 -> 段地址+65536)，如果想确定该内存单元的具体位置，还必须知道该单元在段内的偏移。有了段地址和偏移量，就可以唯一的确定内存单元在存储器中的具体位置。

段式管理(16位CPU)

逻辑地址=段内偏移量

由逻辑地址得到物理地址的公式为:

PA = 段寄存器的值 * 16 + 逻辑地址

为什么要乘16?

段式管理(16位CPU)

段寄存器是为了对内存进行分段管理而增加的，16位CPU有四个段寄存器，程序可同时访问四个不同含义的段。

1) CS + IP：用于代码段的访问，CS 指向存放程序的段基址，IP指向下条要执行的指令在CS段的偏移量，用这两个寄存器就可以得到一个内存物理地址，该地址存放着一条要执行的指令。

段式管理(16位CPU)

2) SS + SP ： 用于堆栈段的访问，SS指向堆栈段的基地址，SP指向栈顶，可以通过SS和SP两个寄存器直接访问栈顶单元的内存物理位置。

段式管理(16位CPU)

3) DS + BX ： 用于数据段的访问。 DS中的值左移四位得到数据段起始地址，再加上BX中的偏移量，得到一个存储单元的物理地址。

4) ES + BX： 用于附加段的访问。 ES中的值左移四位得到附加段起始地址，再加上BX中的偏移量，得到一个存储单元的物理地址。

段式管理(32位CPU)

32位pc的内存管理仍然采用“分段”的管理模式，逻辑地址同样由段地址和偏移量两部分组成，32位pc的内存管理和16位pc的内存管理有相同之处也有不同之处，因为32位pc采用了两种不同的工作方式：实模式和保护模式。

段式管理(32位CPU)

1）实模式

在实模式下，32位CPU的内存管理与16位CPU是一致的。

2) 保护模式

段基地址长达32位，每个段的最大容量可达4G，段寄存器的值是段地址的“选择器”(Selector)，用该“选择器”从内存中得到一个32位的段地址，存储单元的物理地址就是该段地址加上段内偏移量，这与32位CPU的物理地址计算方式完全不同。

段式管理(32位CPU)

32位CPU内有6个段寄存器，其值在不同的模式下具有不同的含义:

1、在实模式下:

段寄存器的值*16就是段地址

2、在保护模式下:

段寄存器的值是一个选择器，间接指出一个32位的段地址

段式管理(32位CPU)

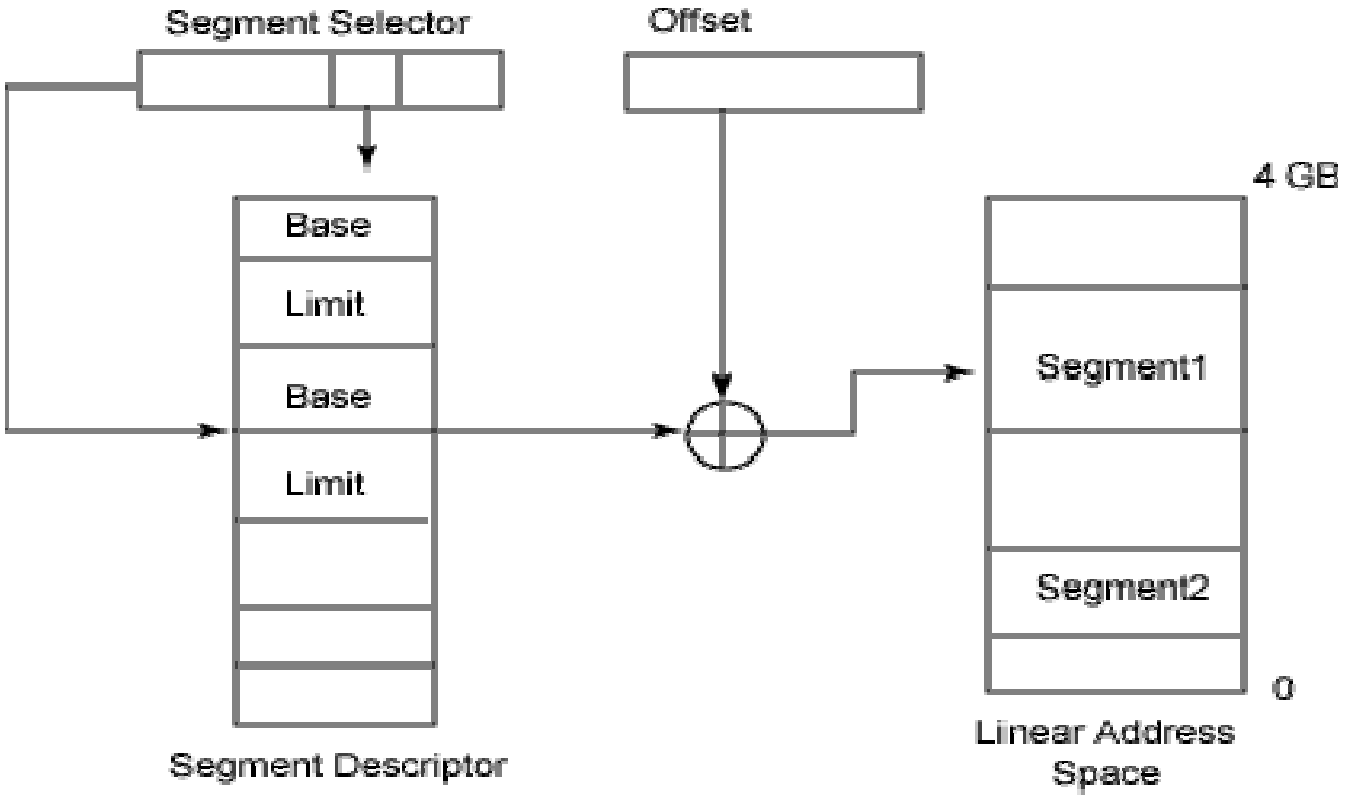

分页管理

从管理和效率的角度出发，线性地址被分为固定长度的组，称为页(page)，例如32位的机器，线性地址最大可为4G，如果用4KB为一个页来划分，这样整个线性地址就被划分为2的20次方个页。

分页管理

另一类“页”，称之为物理页，或者是页框、页桢。分页单元把所有的物理内存也划分为固定长度的管理单位，它的长度一般与线性地址页是相同的。

分页管理

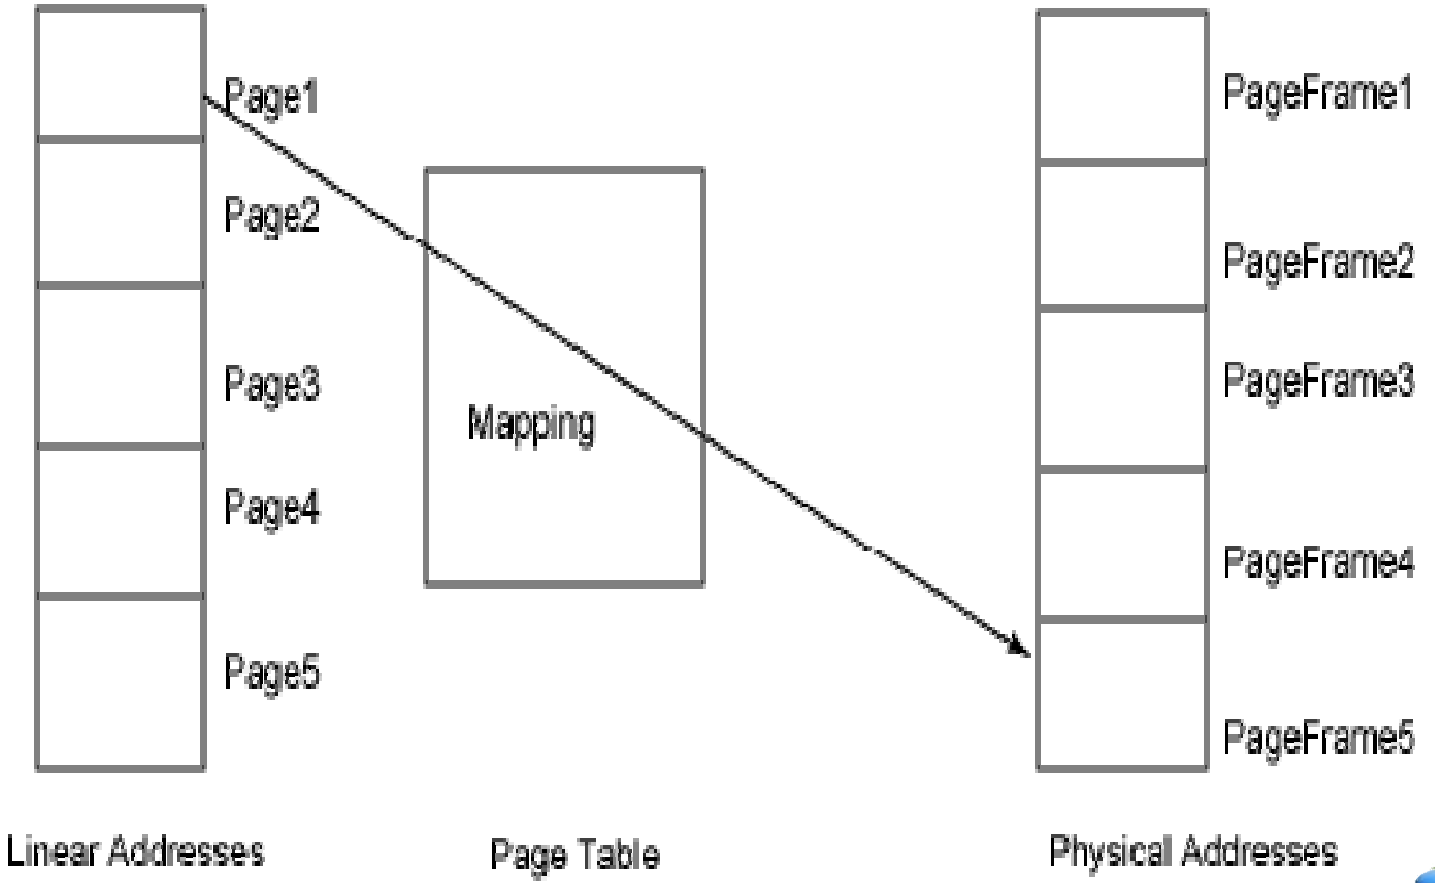

分页管理

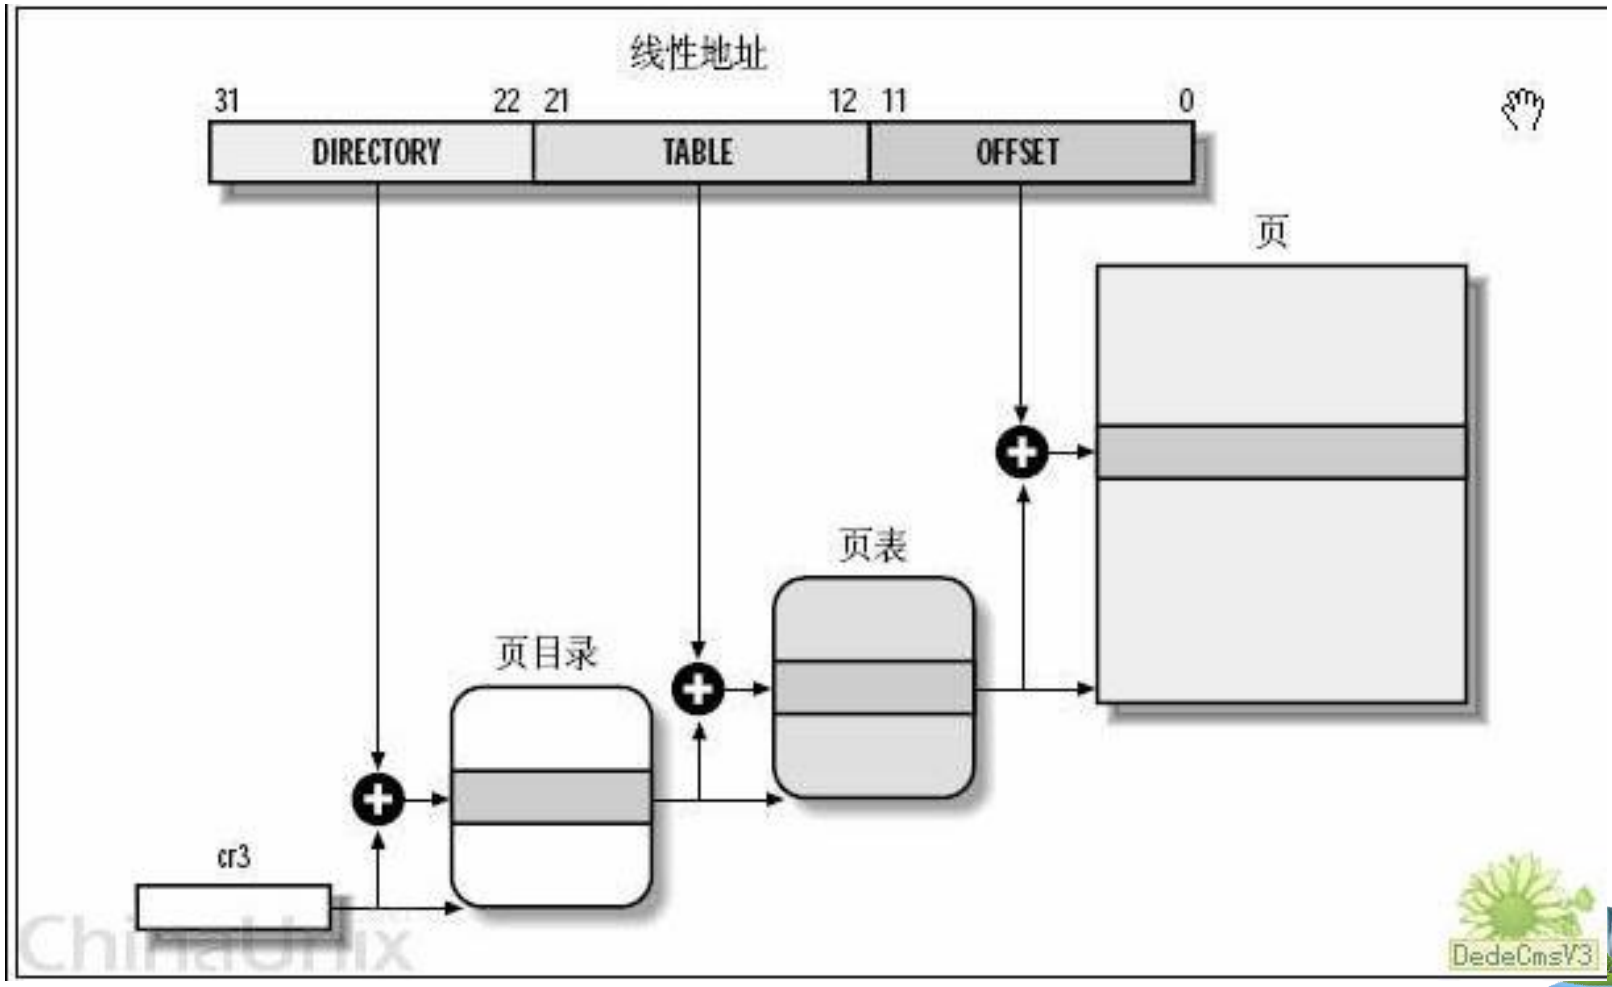

分页管理

1、分页单元中，页目录的地址放在CPU的cr3寄存器中，是进行地址转换的开始点。

2、每一个进程，都有其独立的虚拟地址空间，运行一个进程，首先需要将它的页目录地址放到cr3寄存器中，将其他进程的保存下来。

3、每一个32位的线性地址被划分为三部份：页目录索引(10位)：页表索引(10位)：偏移(12位)

分页管理

依据以下步骤进行地址转换:

1、装入进程的页目录地址（操作系统在调度进程时，把这个地址装入CR3）

2、根据线性地址前十位，在页目录中，找到对应的索引项，页目录中的项是一个页表的地址

3、根据线性地址的中间十位，在页表中找到页的起始地址

4、将页的起始地址与线性地址的最后12位相加，得到物理地址

分页管理

这样的二级模式是否能够覆盖4G的物理地址空间？为什么？（通过计算得出结论）

页目录共有：2^10项，也就是说有这么多个页表；每个目表对应了：2^10页；

每个页中可寻址：2^12个字节。

2^32 = 4GB

Linux内存管理

Linux内核的设计并没有全部采用Intel所提供的段机制，仅仅是有限度地使用了分段机制。这不仅简化了Linux内核的设计，而且为把Linux移植到其他平台创造了条件，因为很多RISC处理器并不支持段机制。

Linux内存管理

所有段的基地址均为0

由此可以得出，每个段的逻辑地址空间范围为0-4GB。因为每个段的基地址为0，因此，逻辑地址到线性地址映射保持不变，在Linux中所提到的逻辑地址和线性地址（或虚拟地址）指的也就是同一地址。看来，Linux巧妙地把段机制给绕过去了，而完全利用了分页机制。

Linux页式管理

前面介绍了i386的二级页管理架构，不过有些CPU(Alpha 64位)使用三级，甚至四级架构，Linux 2.6.29内核为每种CPU提供统一的界面，采用了四级页管理架构，来兼容二级、三级、四级管理架构的CPU。

Linux页式管理

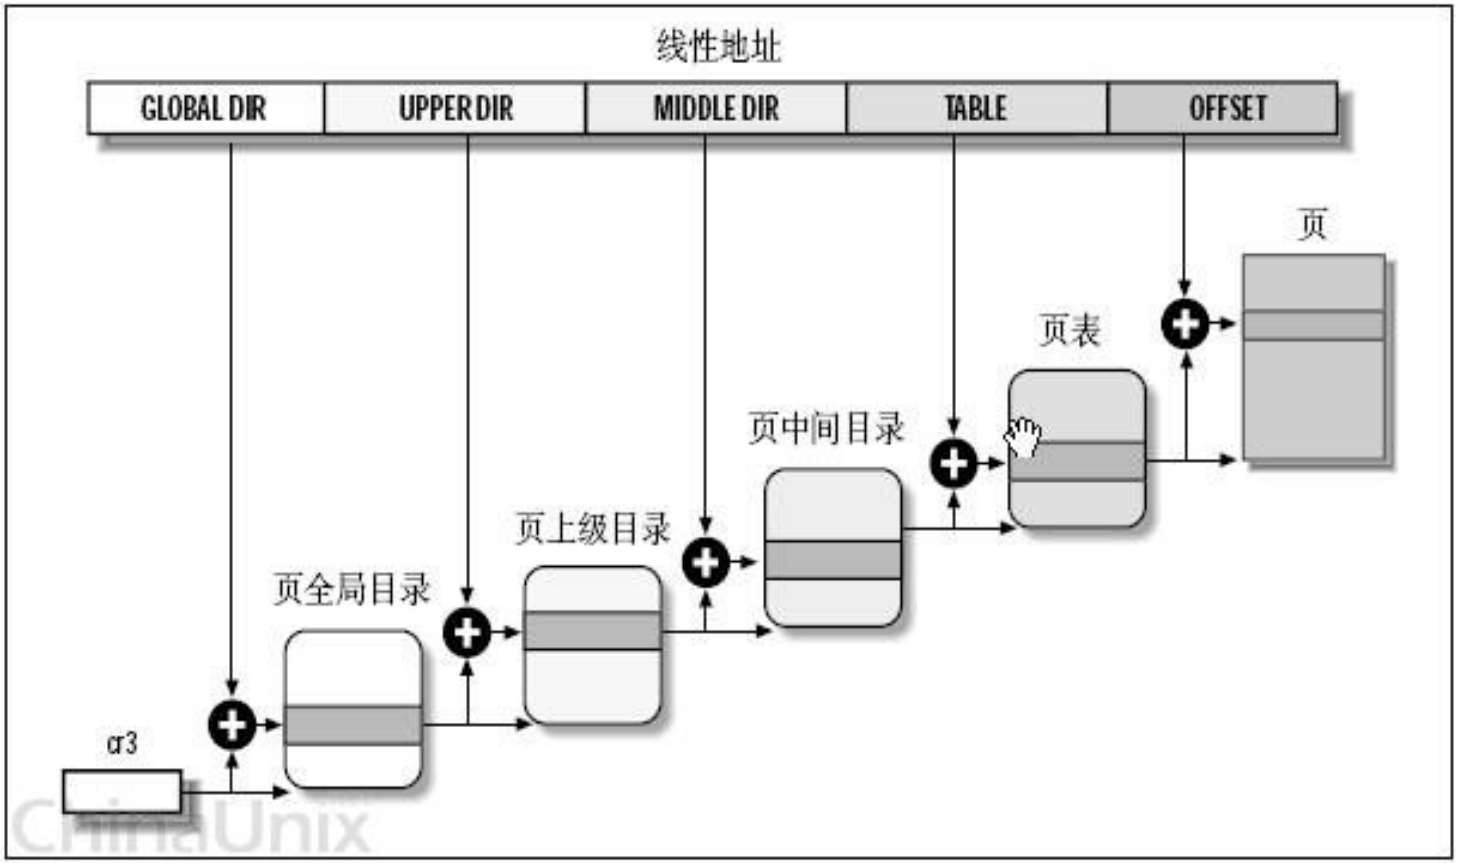

Linux页式管理

这四级分别为:

1. 页全局目录 (Page Global Directory): 即 pgd，是多级页表的抽象最高层。
2. 页上级目录(Page Upper Directory):即pud。
3. 页中间目录(Page Middle Directory): 即 pmd，是页表的中间层。
4. 页表(Page Table Entry): 即 pte。

Contents

www.enjoylinux.cn

- Linux内存管理
- Linux进程地址空间
- Linux内核地址空间
- Linux内核链表
- Linux内核定时器

虚拟内存

Linux操作系统采用虚拟内存管理技术，使得每个进程都有独立的进程地址空间，该空间是大小为3G，用户看到和接触的都是虚拟地址，无法看到实际的物理地址。利用这种虚拟地址不但能起到保护操作系统的作用，而且更重要的是用户程序可使用比实际物理内存更大的地址空间。

虚拟内存

Linux将4G的虚拟地址空间划分为两个部分——用户空间与内核空间。用户空间从0到0xbfffffff，内核空间从3G到4G。用户进程通常情况下只能访问用户空间的虚拟地址，不能访问内核空间。例外情况是用户进程通过系统调用访问内核空间。

进程空间

用户空间对应进程，所以每当进程切换，用户空间就会跟着变化。

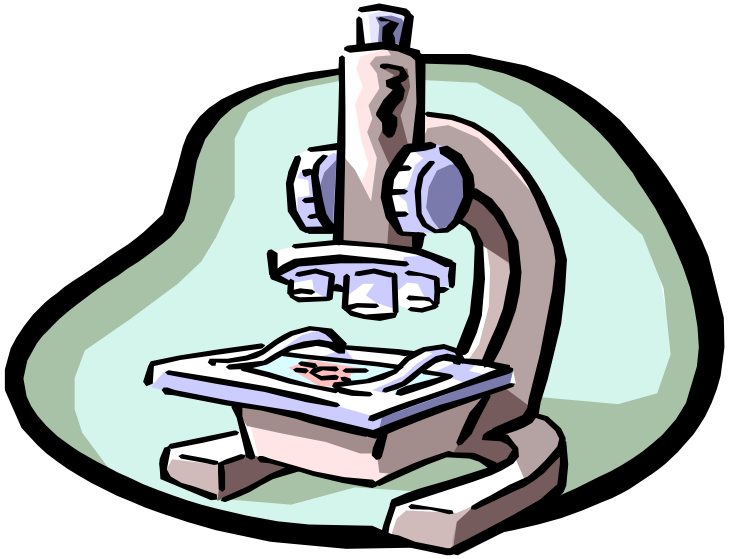

进程空间

每个进程的用户空间都是完全独立、互不相干的。把同一个程序同时运行10次（为了能同时运行，让它们在返回前睡眠100秒），会看到10个进程使用的线性地址一模一样。

（ cat /proc/<pid>/maps ）

进程空间

创建进程fork()、程序载入execve()、动态内存分配malloc()等进程相关操作都需要分配内存给进程。这时进程申请和获得的不是物理地址，仅仅是虚拟地址。

进程空间

实际的物理内存只有当进程真的去访问新获取的虚拟地址时，才会由“请页机制”产生“缺页”异常，从而进入分配实际页框的程序。该异常是虚拟内存机制赖以存在的基本保证——它会告诉内核去为进程分配物理页，并建立对应的页表，这之后虚拟地址才实实在在地映射到了物理地址上。

内核内存分配

在应用程序中，常使用malloc函数进行动态内存分配，而在Linux内核中，通常使用kmalloc来动态分配内存。

kmalloc 原型是:

- #include <linux/slab.h>
- void *kmalloc(size_t size, int flags)

参数:

size:要分配的内存大小。

flags:分配标志, 它控制 kmalloc 的行为。

分配标志

最常用的标志是GFP_KERNEL，它的意思是该内存分配是由运行在内核态的进程调用的。也就是说，调用它的函数属于某个进程的，当空闲内存太少时，kmalloc函数会使当前进程进入睡眠，等待空闲页的出现。

分配标志

如果**kmalloc**是在进程上下文之外调用，比如在中断处理，任务队列处理和内核定时器处理中。这些情况属于中断上下文，不能进入睡眠，这时应该使用优先权**GFP_ATOMIC**。

分配标志

- **GFP_ATOMIC**

  用来在进程上下文之外的代码（包括中断处理）中分配内存，从不睡眠。

- **GFP_KERNEL**

  进程上下文中的分配。可能睡眠。（16M-896M）

- **__GFP_DMA**

  这个标志要求分配能够 DMA 的内存区（物理地址在16M以下的页帧 ）

- **__GFP_HIGHMEM**

  这个标志表示分配的内存位于高端内存。（896M以上）

按页分配

如果模块需要分配大块的内存，那使用面向页的分配技术会更好

- **get_zeroed_page(unsigned int flags)**
  返回指向新页面的指针,并将页面清零。

- **__get_free_page(unsigned int flags)**
  和get_free_page类似，但不清零页面。

- **__get_free_pages(unsigned int flags,unsigned int order)**
  分配若干个连续的页面，返回指向该内存区域的指针，但也不清零这段内存区域。

释放

当程序用完这些页，可以使用下列函数之一来释放它们：

- void free_page(unsigned long addr)
- void free_pages(unsigned long addr, unsigned long order)

如果释放的和先前分配数目不等的页面，会导致系统错误

内存使用

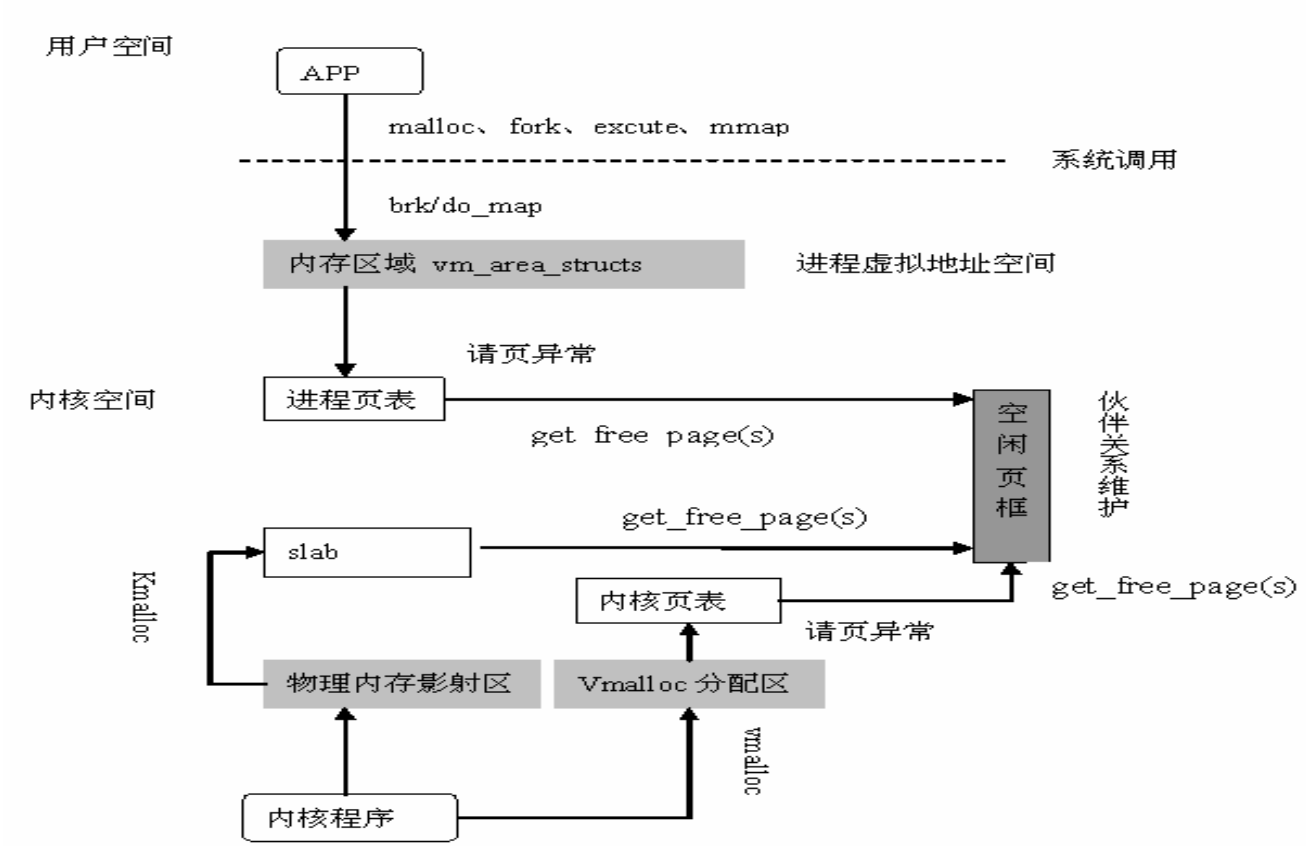

实验

内核内存分配

编写内核模块

1、在模块中使用kmalloc分配内存，并使用分配的内存。

2、在模块中使用按页分配分配内存，并使用分配的内存。

Contents

内核空间

内核空间是由内核负责映射，它并不会跟着进程改变，是固定的。

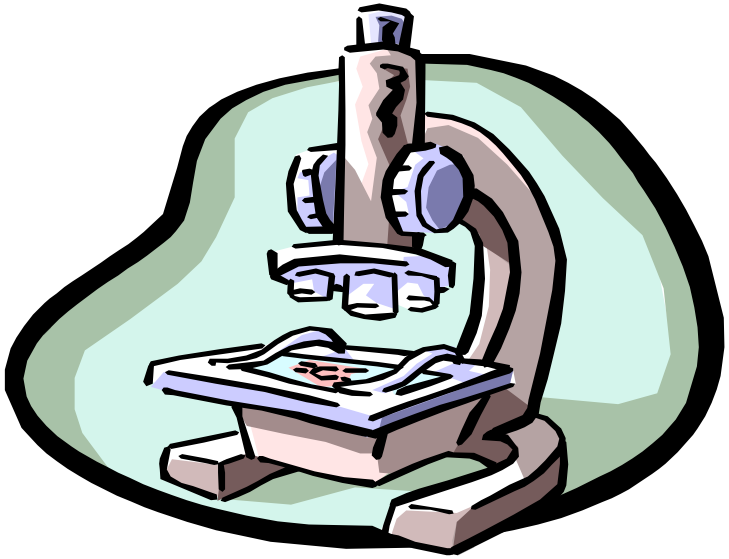

高端内存

物理内存896MB以上的部分称之为高端内存。

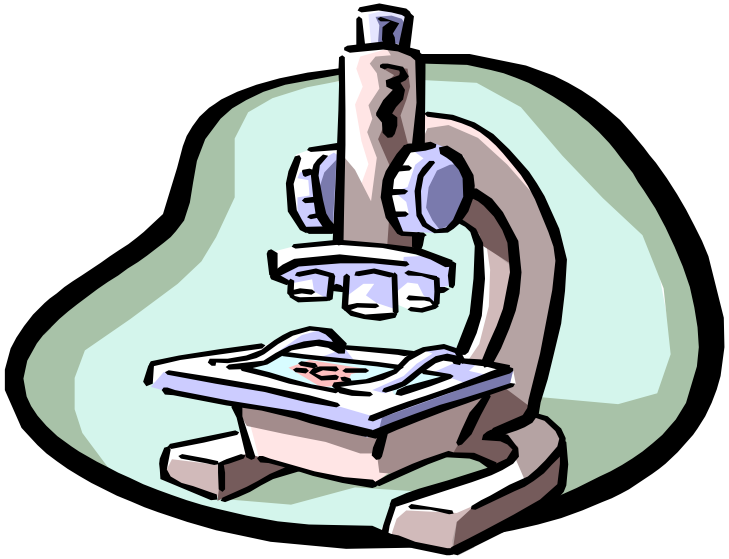

内核空间分布

内核空间分布

直接内存映射区
（Direct Memory Region）

从3G开始，最大896M的线性地址区间，我们称作直接内存映射区，这是因为该区域的线性地址和物理地址之间存在线性转换关系

线性地址=3G + 物理地址

例:

物理地址区间0x100000-0x200000映射到线性空间就是3G+0x100000-3G+0x200000。

内核空间分布

动态内存映射区
（Vmalloc Region）

该区域的地址由内核函数**vmalloc**来进行分配，其特点是线性空间连续，但对应的物理空间不一定连续。**vmalloc**分配的线性地址所对应的物理页可能处于低端内存，也可能处于高端内存。

内核空间分布

永久内存映射区
（PKMap Region ）

对于896MB以上的高端内存，可使用该区域来访问，访问方法:

1. 使用alloc_page(__GFP_HIGHMEM)分配高端内存页
2. 使用kmap函数将分配到的高端内存映射到该区域

内核空间分布

固定映射区
（Fixing Mapping Region）

PKMap区上面，有4M的线性空间，被称作固定映射区，它和4G顶端只有4K的隔离带。固定映射区中每个地址项都服务于特定的用途，如ACPI_BASE等。

Contents

简介

链表是一种常用的数据结构，它通过指针将一系列数据节点连接成一条数据链。相对于数组，链表具有更好的动态性，建立链表时无需预先知道数据总量，可以随机分配空间，可以高效地在链表中的任意位置实时插入或删除数据。链表的开销主要是访问的顺序性和组织链的空间损失。

简介

通常链表数据结构至少包含两个域：数据域和指针域，数据域用于存储数据，指针域用于建立与下一个节点的联系。按照指针域的组织以及各个节点之间的联系形式，链表又可以分为单链表、双链表、循环链表等多种类型。

单向链表

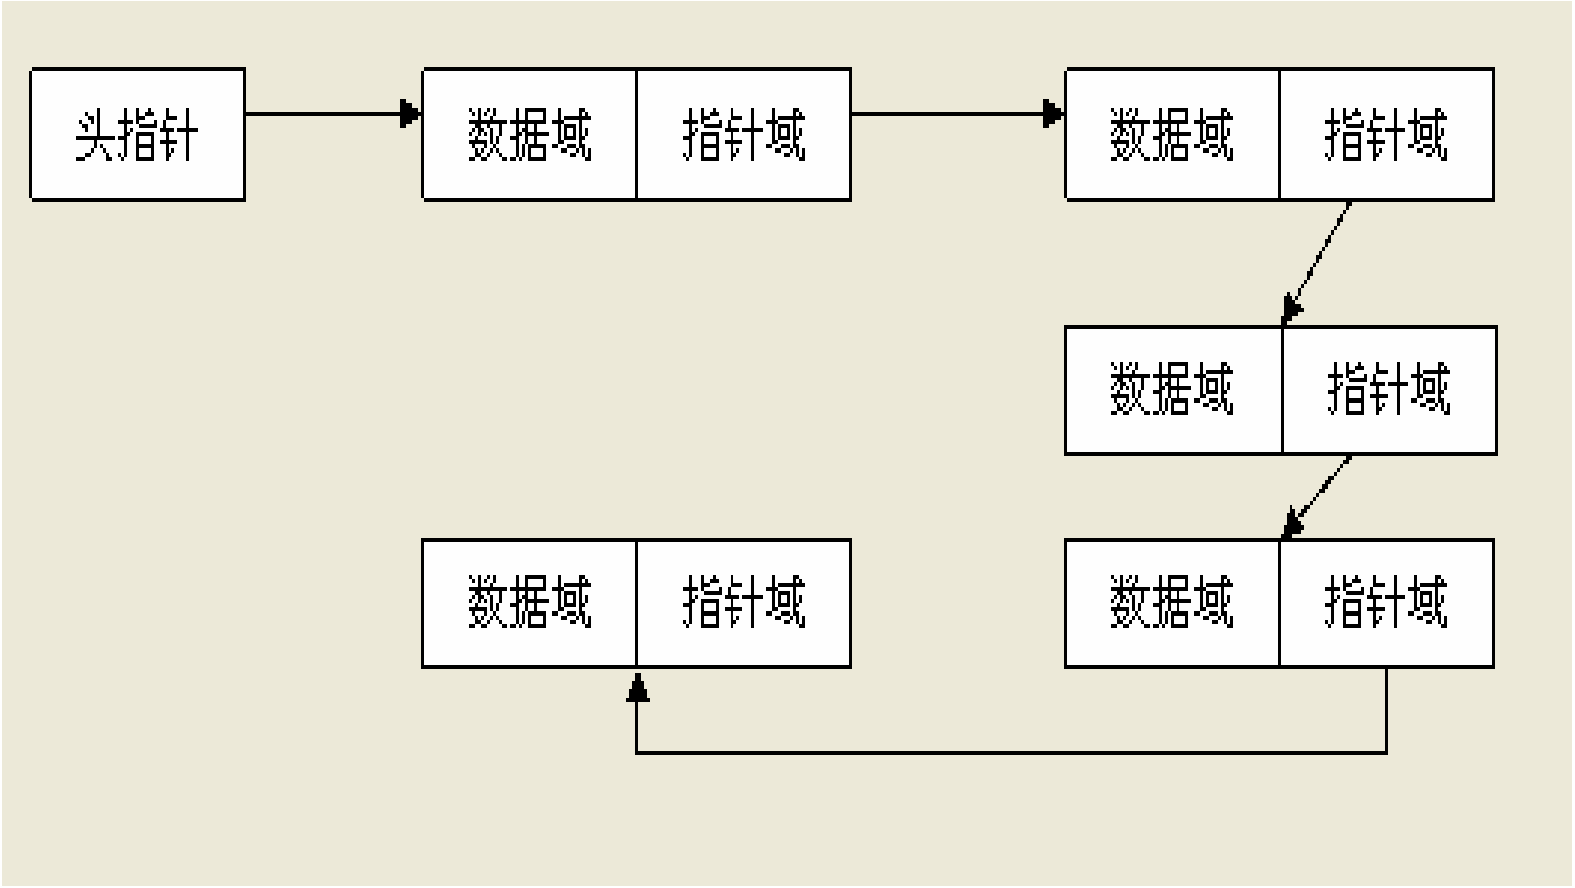

双向链表

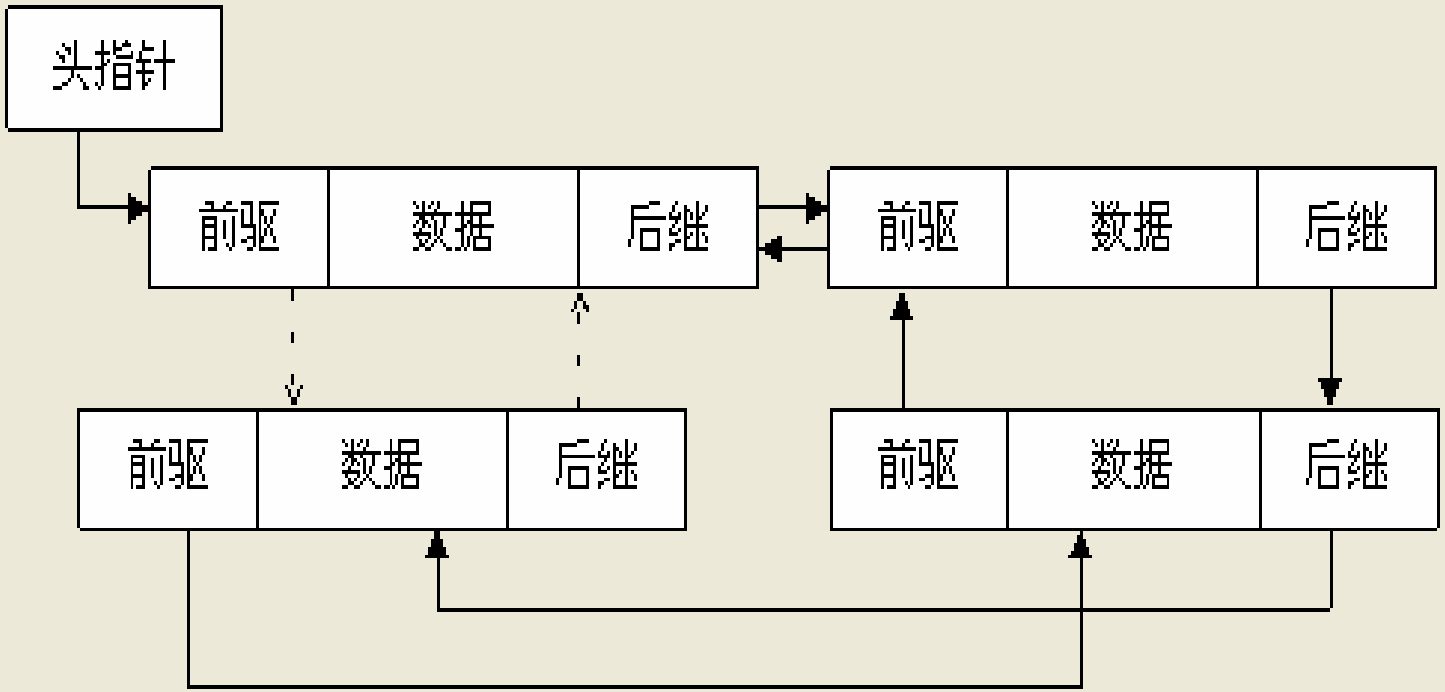

内核链表

在Linux内核中使用了大量的链表结构来组织数据。这些链表大多采用了[include/linux/list.h]中实现的一套精彩的链表数据结构。

内核链表

链表数据结构的定义:

```
struct list_head
{
   struct list_head *next, *prev;
};
```

list_head结构包含两个指向list_head结构的指针prev和next，由此可见，内核的链表具备双链表功能，实际上，通常它都组织成双向循环链表。

传统链表PK内核链表

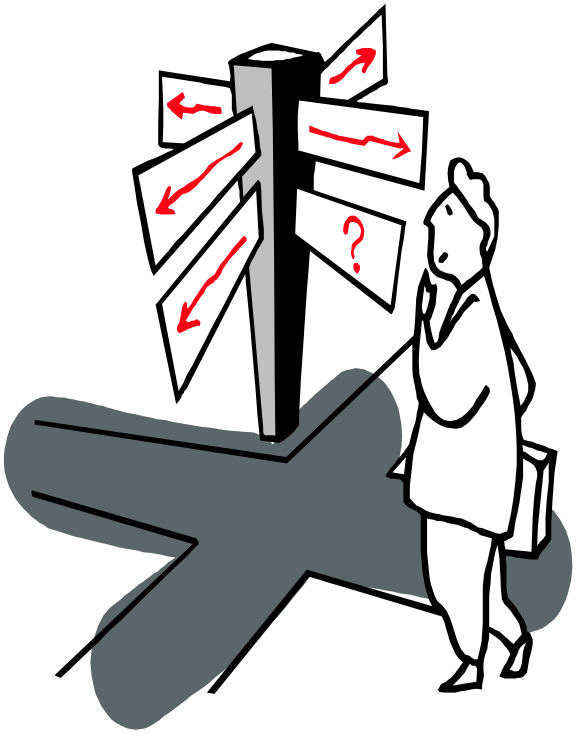

图示区别！

链表操作

Linux内核中提供的链表操作主要有:

- 初始化链表头

INIT_LIST_HEAD(list_head *head)

- 插入节点

list_add(struct list_head *new, struct list_head *head)

list_add_tail(struct list_head *new, struct list_head *head)

链表操作

- 删除节点

list_del(struct list_head *entry)

- 提取数据结构

list_entry(ptr, type, member)

已知数据结构中的节点指针ptr，找出数据结构，例:

list_entry(aup, struct autofs, list)

链表操作

- 遍历

  list_for_each(struc list_head *pos, struc list_head *head)

例:

```
struct list_head *entry;
struct list_head cs46xx_devs; //链表头

list_for_each(entry, &cs46xx_devs)
{
        card = list_entry(entry, struct cs_card, list);
        if (card->dev_midi == minor)
                break;
}
```

链表操作

实例分析

实验

内核链表操作

编写内核模块

1、完成结点的插入 3、完成结点的删除

2、完成链表的遍历

（遍历时访问结点中的数据）

Contents

度量时间差

时钟中断由系统的定时硬件以周期性的时间间隔产生，这个间隔（即频率）由内核根据HZ来确定，HZ是一个与体系结构无关的常数，可配置（50-1200），在X86平台，默认值为1000。

度量时间差

每当时钟中断发生时，全局变量jiffies(unsigned long)就加1，因此jiffies记录了自linux启动后时钟中断发生的次数。驱动程序常利用jiffies来计算不同事件间的时间间隔。

延迟执行

如果对延迟的精度要求不高，最简单的实现方法如下--忙等待:

- unsigned long j=jiffies + jit_delay*HZ;
- while (jiffies<j)

```
{
  /* do nothing */
}
```

内核定时器

定时器用于控制某个函数(定时器处理函数)在未来的某个特定时间执行。内核定时器注册的处理函数只执行一次--不是循环执行的。

内核定时器

内核定时器被组织成双向链表，并使用struct timer_list结构描述。

```
struct timer_list {
    struct list_head entry /*内核使用*/;
    unsigned long expires; /*超时的jiffies值*/
    void (*function)(unsigned long); /*超时处理函数*/
    unsigned long data; /*超时处理函数参数*/
    struct tvec_base *base; /*内核使用*/
};
```

内核定时器

操作定时器的有如下函数:

- **void init_timer(struct timer_list *timer);**

  初始化定时器队列结构。

- **void add_timer(struct timer_list * timer);**

  启动定时器。

- **int del_timer(struct timer_list *timer);**

  在定时器超时前将它删除。当定时器超时后，系统会自动地将它删除。

内核定时器

实例分析

内核定时器

编写内核模块实现定时器